

解释盆地选择动力学

Dynamics of Interpretation Basin Selection
阶段性研究汇报

研究问题

大语言模型为何会收敛到某个答案？

幻觉与推理失稳是否能在内部动力学中提前观察？

是否存在低维变量统一描述推理过程？

核心主张

推理 = 相关性枚举 → 势能差积累 → 盆地选择 → 答案承诺

不是 Prompt → Answer 的直接映射
而是多个解释盆地之间的竞争与选择
后层输出只是前期动力学的显影

整体研究路线

Audit-5: Hidden $\leftrightarrow$ TopK 语义邻域

Audit-6: 邻域动力学与 τ 边界

Constraint-Audit: 约束坍缩与提前预警

UA 系列: ΔU 、Critical Band、 χ

UA-7: LoRA 干预实验

OA 系列: W-C 统一框架

公理一： Hidden State 不是孤立对象

$$H_l \leftrightarrow \mathcal{N}_k(H_l)$$

$$\mathcal{N}_k(H_l) = \text{TopK}(H_l W^\top)$$

隐藏态对应词表诱导的语义邻域

TopK 不是采样策略，而是内部状态的离散语义投影

研究对象从向量转向语义邻域

Audit-5B实验: TopK 保留 hidden topology

仅保留 TopK token identity

不使用 logit value / probability / rank score

仍能保留大量 hidden topology

结论: TopK(H) 不是输出副产物, 而是 hidden geometry 的语义投影。

公理二：传播的是邻域关系

$$\mathcal{N}_k(H_l) \rightarrow \mathcal{N}_k(H_{l+1})$$

传统视角： $H_l \rightarrow H_{l+1}$

本研究视角：语义邻域之间发生演化
层间传播可理解为邻域态射动力学

Audit-6: τ 边界复现

$$\tau \approx L_{20} - L_{22}$$

用 TopK/VIM 邻域状态替代 hidden state

仍复现 L_{20} – L_{22} 附近宏观边界

关系保持变换下 τ 仍稳定

结论： τ 不是 hidden-space 偶然现象，而是宏观动力学边界。

Constraint-Audit: 答案盆地竞争指标

$$R_l = \text{logit}(C) - \text{logit}(E)$$

C: clean / correct basin

E: conflict / error basin

R_l 描述第 l 层对两个答案盆地的偏向

Constraint-Audit-1d实验：提前预警成立

不使用最终层 L27

仅用 L20–L25 的约束轨迹

即可强预测后续 Gen_E

W20–25 是最强 early-warning window

结论：答案坍缩在最终输出前已经显影。

Constraint-Audit-2A~2C实验： 机制坐标

Stable: 稳定机制

Competition: 竞争机制

Closure: 闭包重写 / 约束坍塌机制

W20-25 中可以分离出这些机制结构

Constraint-Audit-3C实验：原型几何

$$\Delta R_{20:25} = \alpha S + \beta K + \gamma Q + \varepsilon$$

S = Stable Prototype

K = Competition Prototype

Q = Closure Prototype

ε = Residual Structure

$\Delta R_{20:25}$ 形成可解释结构空间

UA-1实验：三种动力学相

Positive phase: clean basin 占优

Critical phase: 竞争 / 混合状态

Negative phase: conflict basin 占优

结论：模型内部不是连续混沌，而存在可分离动力学相。

UA-1M实验： 中层决定后层

$$\mathcal{M}_{7:19} \rightarrow \mathcal{C}_{20:22}$$

$$R^2 = 0.729$$

$$corr = 0.854$$

中层特征强预测临界区状态

说明 τ 更像显影边界

真正的势能差积累可能发生在 L7–L19

$\mathcal{M}_{7:19}$ 表示Middle-layer Accumulation State

UA-2A实验：标量场 vs 向量场

检验层间流是否近似无旋

L7–L19 更接近 scalar-like

边界区与后层存在非保守成分

结论：推理动力学不是全程简单梯度下降，而是分层机制。

UA-2C实验: $\text{Dim}(\mathbf{U}) \approx 1$

$$\text{Var}(PC1) = 85.6\%$$

$PC1$ explains 85.6% of the variance in $\Delta R_{20:25}$

$\Delta R_{20:25}$ 的六维轨迹几乎压缩到一维主轴

$PC1+PC2+PC3$ 约 99%

提示存在低维宏观状态变量

结论: 这是发现候选本体变量的关键一步。

UA-2C实验： 补充

$$X = \Delta R_{20:25}$$

其中：

$$X = (\Delta R_{20}, \Delta R_{21}, \dots, \Delta R_{25})$$

PCA 后：

$$X = \sum_i a_i PC_i$$

实验结果：

$$\frac{\lambda_1}{\sum_i \lambda_i} = 0.856$$

其中：

$$\lambda_1$$

是第一主成分特征值。

UA-3A实验： ΔU 作为序参量

$$\Delta U = \Pi_{PC1}(\Delta R_{20:25})$$

其中：

$$\Pi_{PC1}$$

表示：

projection onto the first principal component



即：

$$\Pi_{PC1}(x) = v_1^\top x$$

其中：

$$v_1$$

是 PCA 第一主轴。

Positive > Critical > Negative

ΔU 能预测后续盆地动力学

类似统计物理中的磁化强度 M

结论： ΔU 不只是压缩变量，而是候选序参量。

UA-4B实验： Critical Band

$$U_- < \Delta U < U_+$$

U_- = Lower Critical Boundary

U_+ = Upper Critical Boundary

临界区不是单点阈值

而是有限宽度相变带

critical 样本在带内占据率最高

结论：解释盆地选择更像有限宽度混合相，而非硬阈值分类。

UA-5B实验：响应函数 χ

$$\chi = \left| \frac{\partial P(Gen_E)}{\partial \Delta U} \right|$$

$P(Gen_E)$ = 生成冲突答案的概率

ΔU = 序参量

χ 在 critical band 内最大

χ 衡量系统对 ΔU 微扰的敏感程度。

带内微扰最容易改变最终盆地

出现序参量 $\rightarrow$ 响应函数结构

结论：这使相变类比从语言变成可测结构。

UA-6A实验：证伪简单幂律

未支持经典二级相变幂律

χ 不呈简单 $|\Delta U - U_c|^{-\gamma}$

更像带内饱和 + 带外指数衰减

结论：负结果很重要：系统不是经典 **Ising** 临界点，而是有限宽度混合相。

为什么做 LoRA 干预

前面实验多为观察性证据

LoRA 提供可控参数扰动

可以测试 $W \rightarrow W'$ 是否改变 ΔU / 盆地边界

结论：从描述动力学进入操纵动力学。

UA-7A实验： Code LoRA

稳定盆地几乎不动

竞争盆地显著移动

PC1 主导结构保持

结论： LoRA 不是简单改变输出，而是改变竞争盆地边界。

UA-7B实验：多 LoRA 干预

Code / Math / Medical 三类 LoRA

共同保持 $\text{Dim}(U) \approx 1$

共同移动竞争盆地

不同 LoRA 产生不同扰动方向

结论：LoRA 更像势场扰动算子，而非单纯知识补丁。

OA 系列实验：静态 W 假说的修正

OA-3A 证伪简单 Landscape=W

静态 W 不能直接跨 basin-pair 预测 ΔR

提示约束场不是预先完整存在于 W 中

结论：W 提供先验地形，但推理期约束场需要 prompt 与 T 动态生成。

Prompt 是初始条件生成器

$$\mathcal{I} : \textit{Prompt} \rightarrow \xi_0$$

$\mathcal{I}$ = Initialization Operator

Prompt 不是简单输入文本

浅层 TopK 更像初始语义邻域

OA-4l.1/4l.2 支持 TopK_init $\rightarrow$ Δ R20:25

结论：推理前期首先构造任务流形，而不是直接选择答案。

W-C 统一框架

$$C(x)=W|_x$$

训练：学习约束全集 W

推理：激活局部约束 $C(x)$

Transformer T 执行约束收敛动力学

结论：训练与推理是同一约束系统的不同尺度。

当前分层图景

L0–L6: 相关性枚举 / 任务流形识别

L7–L19: 势能差积累

L20–L22: 临界带 / 盆地选择入口

L23–L26: 答案盆地形成

L27: 输出承诺

已证实结论 vs 工作假说

较稳健：TopK 邻域、 τ 边界、 $\Delta R_{20:25}$ 、 $\text{Dim}(U) \approx 1$ 、Critical Band、 χ 、LoRA扰动

工作假说：W-C 框架、约束场、势能景观本体解释

开放问题：守恒量、跨模型普适性、真实任务泛化

下一阶段计划

Invariant-Audit: 寻找 I_{topo} / I_{rel} / I_{closure}

跨模型复核: Llama / Gemma / DeepSeek

多 LoRA 控制实验: 从扰动到控制

真实 hallucination 任务验证

论文化: 从实验日志到可复现研究报告

总结

大模型推理 = 解释盆地选择动力学

存在低维序参量 ΔU

存在有限宽度 Critical Band

存在响应函数 χ

LoRA 可控扰动竞争盆地

推理可被理解为约束收敛过程